

MINERÍA DE DATOS · 9° CUATRIMESTRE

Capítulo 1

*Introducción a la
Minería de Datos*

Ramsés Camas Nájera, M.Sc. · UPCh · Mayo 2026

SU PROFESOR

Ramsés Alejandro Camas Nájera

Head of AI

MAPS Disruptivo

CTO & Cofundador

RavanTech

¿De dónde vengo?

2022

Ing. en Software

Tuxtla Gutiérrez, Chiapas

2024

M.Sc. Inteligencia Artificial

Universitat Politècnica de València, España

2026 →

M.Sc. Ciencia e Innovación Tecnológica

UPCh · Sistemas Inteligentes

Lo que hago hoy

Head of AI

MAPS Disruptivo · Sistema multi-agente en producción

CTO & Cofundador

RavanTech · IA, VR/AR, software empresarial

Director del Bootcamp de IA

Código Facilito · LangGraph, RAG, MCP, DSPy

Investigador

COMIA 2025 (Springer CCIS) · 2º lugar — VISMAID

§ ESTRUCTURA DEL CURSO

Sobre esta materia

4 unidades · 8 proyectos · 16 semanas

Las 4 unidades

I

Análisis de datos

Regresión, clasificación, evaluación

II

Minería de datos

Texto, embeddings, BERT, RAG, series

III

Agrupamiento

Clustering, detección de anomalías

IV

Minería en sistemas

Data Warehouse, cubos OLAP, dashboard

8 mini-proyectos

M1 · EDA + regresión

M2 · Clasificación clásica

M3 · Data Warehouse

M4 · TF-IDF y topics

M5 · Búsqueda semántica

M6 · Fine-tuning BERT

M7 · XGBoost

M8 · Series temporales

Aún en construcción

Lo que sí sabemos:

Mini-proyectos con defensa oral.

Examen al cierre de cada corte.

Pesos exactos: los anuncio pronto.

Lo que veremos hoy

1. ¿Qué es la minería de datos?
2. El proceso KDD
3. Tipos de datos
4. Tareas de minería
5. Disciplinas relacionadas
6. Aplicaciones e impacto

Minería de datos =

El proceso de descubrir patrones, modelos y conocimiento interesantes en grandes volúmenes de datos.

Vivimos en la era del dato

Terabytes y petabytes a diario.

Empresas. Ciencia. Salud. Redes.

Almacenar es barato.

Entender es lo difícil.

1.1 · ETIMOLOGÍA

¿Por qué “minería”?

Como en la minería de oro:

Extraer un núcleo valioso desde mucho material crudo.

Google Flu Trends

Miles de millones de búsquedas/día.

Si suben búsquedas de “gripe”...

...sube la actividad real de gripe.

2 semanas antes que Salud Pública.

LA LECCIÓN

*Ningún dato individual
contenía la respuesta.*

*El conocimiento emerge
al agregar y minar.*

Los 4 pasos

1 Preparación

2 Minería

3 Evaluación

4 Presentación

Preparación

Limpieza

Integración de fuentes

Transformación

Selección

Minería

Extraer patrones o
construir modelos.

Evaluar y presentar

Paso 3:

Identificar patrones genuinamente interesantes.

Paso 4:

Visualizar y comunicar al usuario.

Tres grandes categorías

Estructurados

BD relacionales, data warehouses

Semi-estructurados

Transacciones, secuencias, grafos

No estructurados

Texto, imagen, video, audio

Almacenados vs streams

Almacenados

datos finitos en repositorio.

Streams

datos infinitos, en tiempo real.

Resumen multidimensional

Agregaciones por dimensiones.

Drill-down y roll-up.

Cubos OLAP.

→ Corte 1, Semanas 4–5

Patrones frecuentes

Itemsets:

{leche, pan} aparecen juntos.

Secuencias:

laptop → mochila → accesorios.

EJEMPLO — REGLA DE ASOCIACIÓN

buys(X, computer)
 $\Rightarrow$
buys(X, webcam)

support = 1% · confidence = 50%

Support y confidence

$$\text{support}(X \Rightarrow Y) = P(X \cup Y)$$

$$\text{confidence}(X \Rightarrow Y) = P(Y \mid X)$$

Clasificación

Predice una categoría.

*Ejemplo:
buen / regular / mal candidato.*

Regresión

Predice un número continuo.

*Ejemplo:
ingresos esperados de un producto.*

Análisis de clusters

Agrupar sin etiquetas.

Maximizar similitud dentro.

Minimizar similitud entre.

Tres clusters de clientes



Deep learning

Redes neuronales profundas.

Aprenden las features
automáticamente.

Outliers / anomalías

Lo raro no es ruido.

Es la señal.

Detección de fraude

Tarjeta gasta de pronto
5× su patrón normal,
en otra ciudad,
en otro tipo de comercio.

Eso es un outlier accionable.

Un patrón es interesante si es...

1 **Comprensible**

2 **Válido**

3 **Útil**

4 **Novedoso**

Dos formas de medirlo

Objetivas

support, confidence, lift.

Subjetivas

inesperado, accionable, valida hipótesis.

La minería sintetiza:

Estadística

Machine Learning

Bases de Datos

Visualización · HCI

NLP · Computer Vision

1.5 · COMPARACIÓN

DM vs ML vs Estadística

Estadística

Inferencia rigurosa.

Machine Learning

Aprender de ejemplos.

Minería de datos

Patrones útiles a escala.

Business Intelligence

Análisis de mercado.
Retención de clientes.

Buscadores web

Streams a escala.
Modelos online.

Redes sociales

Detección de comunidades.
Análisis de sentimiento.

Biomedicina

Genómica.
Diagnóstico personalizado.

Lo que la minería puede mejorar

Descubrimiento científico.

Decisiones de negocio.

Detección de fraude.

Salud pública.

Lo que debemos cuidar

Privacidad personal.

Sesgos algorítmicos.

Vigilancia masiva.

Filtración de datos.

LA PREGUNTA QUE NOS ACOMPAÑA

*¿Para quién es útil
este patrón?*

*¿A quién podría
dañar?*

PRÓXIMA CLASE

Capítulo 2

**Datos, medidas
y preprocesamiento.**