

CLASE 2

Datos, mediciones y preprocesamiento

Conocer los datos antes de minarlos.

MAESTRO

Ramsés Camas Nájera

REFERENCIA

Han, Pei & Tong — Cap. 2

Data Mining: Concepts and Techniques, 4ª ed.

AGENDA DE HOY

1




**Tipos de
atributos**

2



**Estadística
descriptiva**

3



**Similitud
y distancia**

4




**Calidad
y limpieza**

5



**Transformación
y reducción**

Objetivo: salir sabiendo *cuándo aplicar qué* — no memorizar fórmulas.



ANTES DE EMPEZAR

Garbage In, Garbage Out

80 %

del tiempo de un científico de datos
se va en preprocesar datos.

No es opcional. Es el trabajo real.

Modelos arruinados por bad data

Amazon — sistema de hiring

Modelo entrenado con CVs históricos (sesgo: mayoría hombres) → discriminaba candidatas. Cancelado en 2018.

Zillow — predicción de precios

Modelo no ajustó por outliers post-pandemia → compró miles de casas a precios inflados. Pérdida: \$881 M USD.

Hospitales — riesgo de readmisión

Imputación incorrecta de missing values en lab tests → underestimaron riesgo de pacientes negros.

1

BLOQUE 1 · TIPOS DE ATRIBUTOS

Cuatro tipos. Operaciones distintas.



NOMINAL

Categorías sin orden

Ej. color_pelo, ocupación, ID_cliente



BINARIO

Solo dos estados (0/1)

Ej. fumador, gender, test_HIV



ORDINAL

Orden sí, magnitud no

Ej. tallas (S/M/L), rangos militares



NUMÉRICO

Cantidad medible, interval / ratio

Ej. temperatura, peso, edad, salario

1

BLOQUE 1 · TIPOS DE ATRIBUTOS

Qué operación tiene sentido para cada tipo

Operación	Nominal	Binario	Ordinal	Numérico
Igualdad ($=$, $\neq$)	✓	✓	✓	✓
Orden ($<$, $>$)	✗	✗	✓	✓
Resta ($a - b$)	✗	✗	✗	✓
Razón (a / b)	✗	✗	✗	solo ratio
Tendencia central	<i>moda</i>	<i>moda</i>	<i>moda, mediana</i>	<i>moda, med., media</i>



Regla: subir un nivel (*nominal* $\rightarrow$ *ordinal* $\rightarrow$ *numérico*) agrega operaciones, no las quita.

1

BLOQUE 1 · TIPOS DE ATRIBUTOS

Trampa: números que NO son cantidades



Cuidado

Que un atributo se almacene como *número* no significa que sea **cuantitativo**.

Si sumar o promediar no tiene sentido en el dominio del problema, el atributo es **categorico** aunque esté codificado con enteros.

EJEMPLOS DEL MUNDO REAL

customer_ID = 4172

Nominal

Restar IDs es absurdo

zip_code = 29050

Nominal

Código geográfico

satisfacción = 4/5

Ordinal

Orden sí, magnitud no

temperatura = 25 °C

Numérico

interval · 0 ≠ ausencia

edad = 24 años

Numérico

ratio · 0 sí es ausencia

1

BLOQUE 1 · TIPOS DE ATRIBUTOS

También importa: tipo de DATASET



Record / Tabular

Filas y columnas. La forma clásica.

Ej. CSV, RDBMS, Excel



Transactional

Listas de items por transacción.

Ej. carritos de compras, tickets



Sequence

Datos con orden temporal o de posición.

Ej. texto, ADN, time series



Graph / Red

Nodos conectados por relaciones.

Ej. redes sociales, citas, web



Spatial

Datos con coordenadas geográficas.

Ej. GPS, mapas, sensores IoT



Multimedia

No-estructurados de alta dimensión.

Ej. imágenes, audio, video

En esta clase nos enfocamos en **record data** — pero los principios se extienden a los demás tipos.

Tendencia central: cuatro medidas del «centro»

 $\bar{x}$

Media

$$(x_1 + x_2 + \dots + x_n) / n$$

Usar cuando: *Datos simétricos, sin outliers*

 Q_2

Mediana

Valor central de los datos ordenados

Usar cuando: *Datos sesgados o con outliers*

 M

Moda

Valor más frecuente

Usar cuando: *Único para datos categóricos / nominales*

 mid

Midrange

$$(\text{máx} + \text{mín}) / 2$$


Usar cuando: *Quick check; muy sensible a extremos*

2

BLOQUE 2 · ESTADÍSTICA DESCRIPTIVA

¿La distribución es simétrica o sesgada?


SIMÉTRICA



media = mediana = moda

Usa la media


SESGO POSITIVO



moda < mediana < media

Usa la mediana

SESGO NEGATIVO



media < mediana < moda

Usa la mediana

 **Regla empírica de Han:** $\text{media} - \text{moda} \approx 3 \times (\text{media} - \text{mediana})$

2

BLOQUE 2 · ESTADÍSTICA DESCRIPTIVA

Ejemplo: salarios en una startup

10 EMPLEADOS · SALARIOS (MXN / mes)

28K · 28K · 28K · 30K · 30K · 32K · 35K · 38K · 95K · 220K

MEDIA

$$\sum x_i / n$$

$$(28+28+28+30+30+32+35+38+95+220) K / 10$$

56.4 K*Inflada por los dos altos*

MEDIANA

*valor central**Entre 30 K y 32 K (posiciones 5 y 6)***31 K***El salario «típico» real*

MODA

*valor más frecuente**28 K aparece 3 veces***28 K***Lo más común en el equipo*

Si te preguntan «¿cuánto gana la gente aquí?» — ¿con cuál respondes?

Dispersión: ¿qué tan esparcidos están los datos?

Cinco medidas clave

Range $\text{máx} - \text{mín}$

Muy sensible a outliers

Q_1, Q_3 Cuartiles 25/75 %

Robustos a extremos

IQR $Q_3 - Q_1$

Spread del 50 % central


σ^2 (varianza) $\sum(x_i - \bar{x})^2 / n$

Usa la media

σ (std) $\sqrt{\text{varianza}}$

Mismas unidades que x

Anatomía del boxplot



Resumen de 5 números: (mín, Q_1 , mediana, Q_3 , máx)

Detección de outliers: la regla $1.5 \times \text{IQR}$

Sospechoso de outlier si: $x < Q_1 - 1.5 \cdot \text{IQR}$ o $x > Q_3 + 1.5 \cdot \text{IQR}$

Ejemplo paso a paso

Datos	30, 36, 47, 50, 52, 52, 56, 60, 63, 70, 70, 110
Q_1	48.5
Q_3	66.5
IQR	18
Límite inferior	$48.5 - 1.5 (18) = 21.5$
Límite superior	$66.5 + 1.5 (18) = 93.5$
Conclusión	$110 > 93.5 \rightarrow \text{outlier}$


2

BLOQUE 2 · ESTADÍSTICA DESCRIPTIVA

Covarianza y correlación: ¿se mueven juntos?


POSITIVA

$$r > 0$$

ej. $r = 0.85$ 


NEGATIVA

$$r < 0$$

ej. $r = -0.78$ 

SIN CORRELACIÓN

$$r \approx 0$$

ej. $r = 0.04$ 

Pearson: $r = \frac{\sum (a_i - \bar{a})(b_i - \bar{b})}{(n \cdot \sigma_A \cdot \sigma_B)}$ rango: $-1 \leq r \leq +1$



Correlación $\neq$ Causalidad. Una r alta no implica que A cause B.

2

BLOQUE 2 · ESTADÍSTICA DESCRIPTIVA

 χ^2 para correlación entre nominales

Tabla de contingencia (Han, ej. 2.14)

	Male	Female	Σ
fiction	250 (90)	200 (360)	450
non_fiction	50 (210)	1000 (840)	1050
Σ	300	1200	1500

() = frecuencia esperada

Fórmula

$$\chi^2 = \sum (o_i - e_i)^2 / e_i$$

 o_i = frecuencia observada e_i = frecuencia esperada bajo independencia

$$\chi^2 = 507.93$$

→ rechazamos independencia

gender y preferred_reading ESTÁN correlacionados.

Cuatro gráficos que tienes que conocer



Histograma

*Forma de la distribución
de UNA variable*



Boxplot

*Mediana, IQR y outliers
de UNA variable*



Scatter plot

*Relación entre DOS
variables numéricas*




Q-Q plot

*Compara DOS
distribuciones — ¿igual
forma?*

Histograma $\neq$ *Bar chart*. El histograma usa rangos numéricos; el bar chart usa categorías.

¿Por qué medir similitud entre objetos?



Clustering

Agrupar objetos similares en clusters.



Outlier detection

Encontrar objetos muy distintos a todos los demás.



k-NN classification

Clasificar por los k vecinos más cercanos.

SIMILITUD

0 = totalmente distintos
 1 = idénticos

DISIMILITUD / DISTANCIA

0 = idénticos
 $+$ = cada vez más distintos

Distancias para atributos numéricos

$$\text{Minkowski: } d(i, j) = \left(\sum |x_i - x_j|^h \right)^{1/h}$$

MANHATTAN

$$h = 1$$

$$\sum |x_i - x_j|$$

Suma de bloques

EUCLIDEAN

$$h = 2$$

$$\sqrt{\sum (x_i - x_j)^2}$$

Línea recta — la más común

CHEBYSHEV

$$h = \infty$$

$$\max |x_i - x_j|$$

Diferencia máxima

Una distancia es **métrica** si cumple: no-negatividad, $d(i,i)=0$, simetría, desigualdad triangular.

3

BLOQUE 3 · SIMILITUD Y DISTANCIA

Ejemplo: ¿qué tan parecidos son estos pacientes?

Datos clínicos

Atributo	Paciente A	Paciente B	A – B
edad	32	45	13
presión sistólica	120	140	20
fumador (0/1)	0	1	1

Tres distancias, tres respuestas

Euclidean

$$\sqrt{(13^2 + 20^2 + 1^2)}$$

23.88

Trata todo como numérico — la presión domina.

Manhattan

$$|13| + |20| + |1|$$

34

Suma directa de diferencias absolutas.

Jaccard (solo fumador)

$$(r + s) / (q + r + s) = 1/1$$

1.0

Distancia máxima — no coinciden en lo binario.

Mismo dato, distintas distancias. Cada métrica mide algo distinto — elige la que respeta tu dominio.

3

BLOQUE 3 · SIMILITUD Y DISTANCIA

Distancias para atributos categóricos



NOMINAL

$$d(i, j) = (p - m) / p$$

$p = \text{total atributos} \cdot m = \text{matches}$

Ratio de NO-coincidencias



BINARIO ASIMÉTRICO

Jaccard: $d = (r + s) / (q + r + s)$

Ignora la coincidencia 0—0 (negative match)

Útil para tests médicos, ítems en común



ORDINAL

$$\text{rank } z_i = (r_i - 1) / (M_f - 1)$$

Mapear a $[0, 1]$ · luego tratar como numérico

Conserva el orden, normaliza la escala

Casos especiales: coseno y KL divergence

COSENO

$$\text{sim}(x, y) = (x \cdot y) / \|x\| \|y\|$$

Cuándo usarlo:

- Vectores muy *sparse* (muchos 0s)
- Documentos representados como term-frequency
- Cuando 0—0 NO debe contar como similitud

Ignora la magnitud, mide el ÁNGULO entre vectores.

KL DIVERGENCE

$$D_{\text{KL}}(p \parallel q) = \sum p(x) \cdot \ln [p(x) / q(x)]$$

Cuándo usarla:

- Comparar dos *distribuciones de probabilidad*
- Information loss al aproximar p con q
- ML, NLP, modelos generativos

Cuidado: NO es simétrica $\rightarrow D(p \parallel q) \neq D(q \parallel p)$.

4

BLOQUE 4 · CALIDAD Y LIMPIEZA

Seis dimensiones de la calidad de datos



Accuracy

Los valores son correctos



Completeness

No faltan valores ni atributos



Consistency

No hay contradicciones



Timeliness

Los datos están actualizados



Believability

Los usuarios confían en los datos



Interpretability

Es fácil entender qué significan

Calidad depende del **uso** que le vas a dar a los datos.

80 % de tiempo de un científico de datos. Acéptalo.

4

BLOQUE 4 · CALIDAD Y LIMPIEZA

Valores faltantes: seis estrategias

1

Ignorar la tupla

Bajo

Cuando falta la etiqueta de clase y son pocas filas

2

Llenar manualmente

Bajo

Solo viable para datasets pequeños

3

Constante global

Bajo

«Unknown» o $-\infty$. Crea categoría artificial

4

Media / mediana global

Medio

Mediana si está sesgado. Sesga el dataset

5

Media por clase

Alto

Promedio del subgrupo al que pertenece la tupla

6

Predicción del valor

Alto

Regresión, árbol, Bayesian. Conserva relaciones

Método 6 es el más usado en práctica: *preserva las relaciones entre variables.*

4

BLOQUE 4 · CALIDAD Y LIMPIEZA

Datos ruidosos: tres técnicas de suavizado



BINNING — divide en bins y suaviza

Datos ordenados: 4, 8, 15, 21, 21, 24, 25, 28, 34

Bins equal-frequency

[4, 8, 15] [21, 21, 24] [25, 28, 34]

Por medias

[9, 9, 9] [22, 22, 22] [29, 29, 29]

Por fronteras

[4, 4, 15] [21, 21, 24] [25, 25, 34]



REGRESIÓN

Ajusta los datos a una función. Lineal o múltiple. Los valores que se desvían se «alinean» a la curva.



CLUSTERING

Agrupar valores similares. Los que caen fuera de cualquier cluster son outliers candidatos.

4

BLOQUE 4 · CALIDAD Y LIMPIEZA

Errores comunes que arruinan modelos

1

Borrar tuplas con missing «porque sí»

Reduces tu muestra dramáticamente y sesgas hacia los casos «fáciles».

→ *Imputa o predice. Borrar es último recurso.*

2

Imputar la mediana GLOBAL en vez de por subgrupo

La mediana de salario global no representa al subgrupo «junior»; sesgas estimaciones.

→ *Imputa por clase / categoría.*

3

Normalizar ANTES de separar train / test

Información del test se filtra al train → data leakage → métricas infladas.

→ *Ajusta el scaler con train. Aplica el mismo scaler al test.*

4

Eliminar outliers sin entender por qué existen

Pierdes los casos más interesantes (fraude, eventos raros) que tu modelo necesita.

→ *Investiga primero. Etiqueta como outlier ≠ borrar.*

4

BLOQUE 4 · CALIDAD Y LIMPIEZA

Integración: juntar datos de fuentes distintas

A

Entity identification

¿customer_id (DB1) = cust_number (DB2)?

→ Usar metadata: nombre, tipo, rango, reglas

B

Redundancia

Atributos derivables uno de otro (annual_revenue)

→ Análisis de correlación: r de Pearson, χ^2

C

Duplicación de tuplas

El mismo cliente aparece dos veces con datos distintos

→ Detectar duplicados, consolidar, normalizar

D

Conflictos de valor

Peso en kg en DB1 vs lb en DB2; fechas en formatos distintos

→ Definir convenciones únicas y transformar

5

BLOQUE 5 · TRANSFORMACIÓN Y REDUCCIÓN

Normalización: tres métodos esenciales

Min-Max

$$v' = \frac{(v - \min)}{(\max - \min)}$$

Rango: Rango [0, 1]

Usar cuando: Cuando conoces min y max y no esperas outliers

ejemplo

$v=73K$, [12K, 98K] → 0.716

Z-score

$$v' = \frac{(v - \mu)}{\sigma}$$

Rango: Media 0, std 1

Usar cuando: Cuando hay outliers o no sabes el rango real

ejemplo

$v=73K$, $\mu=54K$, $\sigma=16K$ → 1.225

Decimal scaling

$$v' = v / 10^j$$

Rango: Mueve el punto decimal

Usar cuando: Rangos muy grandes con magnitudes mezcladas

ejemplo

917 → 0.917 ($j = 3$)

5

BLOQUE 5 · TRANSFORMACIÓN Y REDUCCIÓN

Discretización: numérico → categórico

Edad (numérico):

18, 22, 35, 47, 62, 71, ...



Intervalos:

[18-30] [30-50] [50+]



Conceptos:

youth · adult · senior

TOP-DOWN / SPLITTING

Encuentra split-points y divide recursivamente.

Equal-width: todos los bins miden lo mismo

Equal-frequency: todos los bins tienen ~mismo n

Sensible al # de bins y a outliers.

BOTTOM-UP / MERGING

Empieza con todos los valores y va fusionando vecinos.


Supervised: usa la etiqueta de clase (ej. ChiMerge con χ^2)

Unsupervised: histograma, clustering

Genera jerarquía de conceptos automáticamente.

Reducción dimensional: dos enfoques

PCA — Principal Components Analysis



Combina **atributos** en nuevas variables (componentes) que capturan la mayor varianza.

- Funciona en datos linealmente separables
- *No lineal*: **KPCA**, **t-SNE**

ATTRIBUTE SUBSET SELECTION

1

Forward selection

Empieza vacío. Agrega el mejor.

2

Backward elimination

Empieza con todo. Quita el peor.

3

Combinación fwd + bwd

Cada paso: agrega mejor + quita peor.

4

Decision tree induction


Lo que no aparece en el árbol, fuera.

5

BLOQUE 5 · TRANSFORMACIÓN Y REDUCCIÓN


PCA en 3 pasos visuales

1

Datos correlacionados


x_1 y x_2 varían juntos. La info real es ~1D.

2

Encontrar la dirección de máxima varianza

PC1: el «eje» donde los datos están más extendidos.

3

Rotar a los nuevos ejes

PC1 horizontal, PC2 vertical. PC2 aporta poco → se descarta.


Importante: PCA no inventa datos. Solo encuentra nuevos ejes — los datos son los mismos.

5


BLOQUE 5 · TRANSFORMACIÓN Y REDUCCIÓN

Cuando lo lineal no alcanza: KPCA & t-SNE


DATOS ORIGINALES

*Dos clases entrelazadas en 2D*

PCA (lineal)

*Solo rota — no separa*

KPCA / t-SNE

*Separa las clases en el nuevo espacio*

KPCA (kernel trick) · **t-SNE** (preserva vecindades probabilísticas, ideal para visualización 2D / 3D)


Sampling: cuatro maneras de muestrear



SRSWOR

*Simple Random Sample · Sin
reemplazo*

Cada elemento se saca una sola vez



SRSWR

*Simple Random Sample · Con
reemplazo*

Un elemento se puede sacar varias veces



CLUSTER

Muestreo por grupos

Agrupar por páginas/regiones, muestrear grupos



STRATIFIED

Muestreo estratificado

Garantiza representación de cada estrato



Una página para tu mochila

ESTADÍSTICA	DISTANCIAS	LIMPIEZA	TRANSFORMACIÓN
Tendencia media · mediana · moda	Manhattan (h=1) $\sum x_i - x_{\square} $	Faltantes predicción > por clase > global	Min-Max $(v - \min) / (\max - \min)$
Dispersión range · IQR · σ	Euclidean (h=2) $\sqrt{\sum (x_i - x_{\square})^2}$	Ruido (binning) means · boundaries · widths	Z-score $(v - \mu) / \sigma$
Outlier $x < Q_1 - 1.5 \cdot \text{IQR}$ o $Q_3 + 1.5 \cdot \text{IQR}$	Chebyshev (h=∞) $\max x_i - x_{\square} $	Ruido (smoothing) regresión · clustering	Decimal scaling $v / 10^j$
Correlación num. Pearson $r \in [-1, +1]$	Nominal $(p - m) / p$	Integración entity ID · redundancia · conflictos	Discretización top-down · bottom-up
Correlación nom. χ^2 (rechaza independencia)	Jaccard (binary) $(r + s) / (q + r + s)$	Redundancia num. r de Pearson	Reducción lin. PCA · attribute selection
Sesgo media - moda $\approx 3 \cdot$ (media - mediana)	Coseno $(x \cdot y) / \ x\ \ y\ $	Redundancia nom. χ^2	Reducción no-lin. KPCA · t-SNE



CIERRE · CUÁNDO USAR QUÉ

Mapa rápido de decisión

Tengo valores faltantes

Hay outliers

Mis atributos están en escalas distintas

Mis atributos son demasiados

Quiero comparar dos textos

Quiero comparar dos distribuciones

Mis atributos son categóricos mixtos

→ *Método 6 (predicción) si tienes tiempo; mediana si no*

→ *Regla $1.5 \times IQR$; considera mediana en vez de media*

→ *z-score si hay outliers; min-max si no*

→ *PCA si son lineales; KPCA / t-SNE si no*

→ *Coseno (term-frequency vectors)*

→ *KL divergence*

→ *Fórmula de mixed types (Han, ec. 2.27)*



MAÑANA · PRÁCTICA DE 120 MIN

Lo que veremos esta clase, lo aplicamos al dataset real

STACK & DATASET

- **Python:** pandas + polars + plotly
- **Dataset:** *INEGI Chiapas (primero) o Kaggle como fallback*
- **Repo:** github.com/upch-mineria-2026a



DEFENSA ORAL

«*Explícame en 3 minutos qué hiciste en el ejercicio N*»

Sin defensa = reprobado, aunque el código corra.

Pueden usar IA, pero deben entender cada línea.

8 EJERCICIOS

1. Clasificar atributos por tipo
2. Estadística descriptiva + interpretación
3. Detectar outliers con IQR + decidir qué hacer
4. Matriz de correlación + χ^2 nominal
5. Limpiar missing values con 3 estrategias
6. Aplicar y comparar 3 normalizaciones
7. Calcular distancias entre registros
8. Reducir a 2D con PCA + visualizar

PREGUNTAS

¿Qué se llevan?

- 1 *El tipo de atributo decide qué operaciones puedes hacer.*
- 2 *Sin entender la distribución, todas tus métricas mienten.*
- 3 *Limpiar datos no es opcional. Es el 80 % del trabajo real.*

LECTURA OBLIGATORIA

Han, Pei & Tong — Cap. 2 completo (secciones 2.1 → 2.6) antes del viernes.